

Trabalho Prático 01 — Classificação KNN

Relatório de Comparação entre Classificadores

Anderson Fernandes Barbosa João Pedro Brites

Disciplina: GCC 128 — Inteligência Artificial | **Professores:** Ahmed Ali Abdalla Esmin, Anna Paula Figueiredo

Curso: Ciência da Computação | Lavras, 2 de setembro de 2026

Vídeo de apresentação:

https://drive.google.com/file/d/1J2IOTX_zKS0sFaXDJd3y_D9c6ocdswea/view?usp=sharing

Introdução

Este relatório apresenta a comparação entre dois classificadores K-Nearest Neighbors (KNN) aplicados à base de dados Iris (150 amostras, 3 classes): uma implementação desenvolvida manualmente (*hardcore*, com distância euclidiana e votação por maioria) e uma implementação utilizando a biblioteca *scikit-learn*. Ambas foram avaliadas para $k = \{1, 3, 5, 7\}$, com base de teste de 45 amostras (30% do total, particionamento estratificado).

Resultados da Comparação

A Tabela 1 mostra que as métricas de qualidade (acurácia, precisão e revocação macro) foram **idênticas** entre as duas implementações para todos os valores de k testados (diferença média de 0,0000 em todas as métricas), confirmando que a implementação manual reproduz corretamente a lógica do algoritmo KNN. O melhor desempenho foi obtido com $k = 5$ (acurácia de 97,78%), enquanto $k = 1$ apresentou o pior resultado (93,33%) devido à maior sensibilidade a ruído local.

k	Acurácia	Precisão (macro)	Revocação (macro)
1	93,33%	94,44%	93,33%
3	95,56%	96,08%	95,56%
5	97,78%	97,92%	97,78%
7	95,56%	96,08%	95,56%

Tabela 1: Métricas de avaliação (idênticas para KNN manual e *scikit-learn*)

As matrizes de confusão das duas abordagens também foram idênticas em todos os k ; para $k = 5$ (melhor resultado), houve apenas 1 erro entre *versicolor* e *virginica*: $\begin{bmatrix} 15 & 0 & 0 \\ 0 & 15 & 0 \\ 0 & 1 & 14 \end{bmatrix}$.

Já em relação ao **tempo de execução**, houve diferença expressiva: a implementação *scikit-learn* foi de 8 a 10 vezes mais rápida que a manual (Tabela 2), pois utiliza estruturas otimizadas internamente, enquanto a versão manual calcula a distância euclidiana ponto a ponto em laço Python.

k	Tempo manual (s)	Tempo sklearn (s)	Ganho de velocidade
1	0,0405	0,0050	8,1×
3	0,0434	0,0042	10,3×
5	0,0412	0,0044	9,4×
7	0,0419	0,0045	9,3×

Tabela 2: Tempo de execução (treinamento + predição sobre 45 amostras de teste)

Análise e Conclusão

A comparação mostrou que ambos os modelos têm desempenho **equivalente em qualidade de classificação** na base Iris, com pequenas variações conforme k : $k = 5$ foi o mais equilibrado, com maior acurácia e menor taxa de erros, enquanto $k = 1$ (mais sensível a ruído) e $k = 7$ (excesso de suavização) tiveram desempenho levemente inferior. A implementação manual foi útil para evidenciar o funcionamento interno do algoritmo (cálculo de distâncias e votação por maioria), enquanto a *scikit-learn* mostrou-se mais prática e, sobretudo, mais eficiente em tempo de execução. Em suma, o estudo confirma que o KNN é uma técnica simples, robusta e eficaz para classificação de dados tabulares como a Iris, reforçando o valor de comparar uma implementação própria com uma já consolidada em bibliotecas.