

Trabalho Prático 03 - MLPClassifier

GCC 128 - Inteligência Artificial | Professor: Ahmed Ali Abdalla Esmin
Anderson Fernandes Barbosa e João Pedro Brites

Objetivo e método. O MLPClassifier do scikit-learn e o KNN (k=5) foram avaliados nas bases Iris (150 amostras, 4 atributos) e Wine (178 amostras, 13 atributos). Em cada base, os modelos usaram a mesma divisão estratificada: 70% treino e 30% teste, com random_state=42. Os pipelines ajustam StandardScaler apenas no treino. O MLP usa uma camada oculta de 10 neurônios, ativação ReLU e solver Adam. Precisão e revocação são médias macro.

Resultados no conjunto de teste

Base	Classificador	Acurácia	Precisão	Revocação
Iris	KNN (k=5, padronizado)	0,9111	0,9298	0,9111
Iris	MLPClassifier	0,9556	0,9556	0,9556
Wine	KNN (k=5, padronizado)	0,9444	0,9444	0,9524
Wine	MLPClassifier	1,0000	1,0000	1,0000

Análise. Na Iris, o MLP acertou 43 das 45 amostras, contra 41 do KNN padronizado; os erros do MLP foram uma versicolor e uma virginica. Na Wine, o MLP acertou as 54 amostras, enquanto o KNN confundiu três amostras da classe 1 com a classe 2. O MLP convergiu nas duas bases (1.060 iterações na Iris e 634 na Wine), mas seu treinamento foi mais demorado neste computador. Esses tempos são dependentes do ambiente.

Comparação com o TP01 e conclusão. O KNN manual sem padronização do TP01 obteve na Iris acurácia 0,9778, precisão macro 0,9792 e revocação macro 0,9778. Portanto, embora o MLP tenha superado o KNN padronizado neste experimento, não superou a referência original do TP01 na Iris. A escala dos atributos influenciou a comparação. O MLP teve o melhor resultado na Wine e empatou todas as métricas nessa partição; isso não prova superioridade geral. Uma conclusão mais robusta exige validação cruzada e teste de outras configurações.

Vídeo de apresentação: COLE_AQUI_O_LINK_DO_VIDEO